

Rilevamento del COVID-19 da TAC del torace

Definizione del problema

Motivazione

La pandemia di COVID-19 ha generato una domanda senza precedenti di strumenti diagnostici rapidi e scalabili. La tomografia computerizzata (TAC) del torace e' sensibile alle opacita' a vetro smerigliato e ai pattern di consolidamento caratteristici della polmonite da SARS-CoV-2, e il triage radiologico e' stato proposto come complemento al test RT-PCR quando la capacita' di laboratorio e' limitata.

Definizione del task

Data una singola slice assiale di TAC in formato PNG, il sistema deve produrre una etichetta binaria: **COVID** (polmonite da SARS-CoV-2 presente) oppure **Non-COVID** (altre patologie o paziente sano). Il criterio di prestazione primario e' la **sensibilita' (recall) ≥ 0.95** sulla classe positiva, dando priorita' alla riduzione dei falsi negativi rispetto ai falsi positivi: mancare un caso COVID comporta un rischio clinico maggiore rispetto a una quarantena non necessaria.

Dataset

Il dataset SARS-CoV-2 CT-Scan [1] contiene 2 481 immagini PNG raccolte in ospedali brasiliani e distribuite sotto licenza CC BY 4.0:

Split	COVID	Non-COVID	Totale
Train (70%)	876	860	1 736
Val (15%)	188	184	372
Test (15%)	188	185	373

Gli split sono stratificati per etichetta con `random_state=42`.

Limite noto: il dataset non fornisce identificatori paziente. Slice dello stesso paziente possono comparire in split diversi, introducendo un potenziale bias da data leakage che puo' sovrastimare la capacita' di generalizzazione. Questo limite e' dichiarato esplicitamente in tutta l'analisi.

Metodologia

Preprocessing

Le immagini grezze passano attraverso una pipeline fissa prima di essere date in pasto ai modelli:

1. **Caricamento** - OpenCV legge i PNG come uint8; le immagini BGRA vengono convertite in RGB.
2. **Resize con padding** - resize preservando l'aspect ratio a 224 x 224 con padding nero (nessuna distorsione).
3. **Lung masking** - thresholding di Otsu + closing/opening morfologici + selezione delle due componenti piu' grandi isola il campo polmonare e azzerà i tessuti di background. Quando disponibile si usa il modello deep (lungmask U-Net [2]).
4. **Costruzione a tre canali** - la slice grayscale viene espansa a tre canali: (originale, CLAHE clip=2.0, CLAHE clip=4.0). Questo aumenta il contrasto visivo per la CNN senza aggiungere immagini separate.
5. **Normalizzazione** - normalizzazione per canale con media/deviazione standard calcolate **solo sul training split** da `scripts/compute_norm_stats.py` e salvate in `configs/norm_stats.json` (media = [0.475, 0.446, 0.433], std = [0.366, 0.348, 0.336]). Se il file manca, la pipeline ricade sulle statistiche ImageNet; le statistiche del test set non vengono mai usate.

Augmentation in training (nessun flip verticale: anatomicamente scorretto per la TAC del torace): flip orizzontale (p=0.5), rotazione $\pm 10^\circ$ (p=0.5), jitter di luminosita'/contrasto (p=0.5), scale affine 0.9-1.1 (p=0.5), rumore gaussiano (p=0.5).

Estrazione delle feature classiche

Le feature handcrafted vengono estratte dall'immagine grayscale preprocessata e concatenate in un singolo vettore di dimensione 26 366:

Descrittore	Dimensioni	Parametri
Uniform LBP	26	P=24, R=3
GLCM	96	4 distanze x 4 angoli x 6 statistiche
HOG	26 244	9 bin, celle 8x8, blocchi 2x2

Modelli baseline classici

Due pipeline vengono addestrate con GridSearchCV stratificata a 5 fold:

SVM (kernel RBF): StandardScaler -> PCA(200) -> SVC. La PCA riduce il vettore a 26 366 dimensioni a 200 componenti principali per ragioni di trattabilita' computazionale; le 200 componenti conservano > 95% della varianza. Griglia: C in {0.1, 1, 10, 100}, gamma in {scale, 0.001, 0.01}.

Random Forest: RandomForestClassifier. Griglia: n_estimators in {100, 300, 500}, max_depth in {None, 10, 20}.

Modello deep

Architettura: EfficientNet-B0 (timm, pretrained su ImageNet) con head di classificazione personalizzata:

GlobalAveragePool -> Dropout(0.5) -> Linear(1280, 2).

Fine-tuning a due fasi:

- *Fase 1 (solo head, 10 epoche)*: backbone congelata, Adam $lr=1 \times 10^{-3}$, ReduceLROnPlateau(patience=3). Miglior checkpoint salvato su val_loss.
- *Fase 2 (unfreeze parziale, fino a 30 epoche)*: ultimi 2 block stage + conv_head + bn2 scongelati, AdamW $lr=1 \times 10^{-5}$, weight_decay= 1×10^{-4} , early stopping con patience=7.

Training a precisione mista (AMP) abilitato su GPU (disabilitato in automatico su CPU).

Post-processing


Temperature scaling: lo scalare $T > 0$ viene ottimizzato con LBFGS sulla negative log-likelihood del validation set per correggere l'eccesso di fiducia prima della selezione della soglia.

Tuning della soglia: la soglia di decisione viene fatta scorrere da probabilit  alta a bassa; viene selezionato il valore pi  basso che raggiunge recall ≥ 0.95 sulle probabilit  calibrate di validazione, dando priorit  alla sensibilit .

TTA (Test-Time Augmentation): in inferenza vengono generate cinque viste augmentate di ogni immagine di test; le probabilit  softmax vengono mediate.

Ensemble: media pesata delle probabilit  di pi  checkpoint addestrati indipendentemente (pesi proporzionali all'AUC di validazione).

Grad-CAM: le class activation map evidenziano le regioni della TAC pi  influenti per la predizione della classe positiva, abilitando l'ispezione visiva del comportamento del modello.




Risultati sperimentali

Baseline classiche


Risultati sul test set held-out (n = 373):

Modello	Accuracy	Recall	F1	AUC-ROC
Random Forest	0.887	0.878	0.887	0.952
SVM (PCA-200, C=100)	0.962	0.968	0.963	0.996

L'SVM raggiunge un AUC quasi perfetto, superando nettamente il Random Forest. Il gap e' coerente con la letteratura: le feature di texture handcrafted (HOG + LBP + GLCM) sono altamente discriminative per questo task e il kernel RBF sfrutta efficacemente la struttura non lineare nello spazio proiettato dalla PCA.



Matrici di confusione



Deep learning (training completo)

EfficientNet-B0 e' stato fine-tunato per 40 epoche (10 solo testa + 30 fine-tuning completo) su una GPU RTX 3080 locale in 3 h 59 min. Lo schedule a due fasi e' arrivato a termine senza early stopping - la validation loss continuava a migliorare, miglior checkpoint alla fase 2 epoca 27 (val_loss = 0.165). Metriche sul test set (373 immagini):

Modello	Accuracy	Recall	F1	AUC-ROC
EfficientNet-B0 (fine-tuned, soglia=0.50)	0.933	0.920	0.933	0.981
+ Temperature scaling (T=1.002)	0.933	0.920	0.933	0.981
+ Soglia tarata per sensibilita' (soglia=0.358)	0.912	0.931	0.914	0.981
+ TTA (5 viste deterministiche)	0.944	0.942	0.944	0.990

Note sui passi di post-processing:

- La **lung mask** era attiva per tutto il run, ma la U-Net di `lungmask` rifiuta input PNG a 8 bit (si aspetta volumi in unita' Hounsfield), quindi la pipeline e' silenziosamente ricaduta sul fallback Otsu + morfologia per ogni slice. La "lung mask" riportata e' dunque il fallback classico, non la U-Net.
- Il **temperature scaling** ha trovato $T = 1.002$: il modello era gia' ben calibrato, quindi lo scaling lascia le metriche di decisione sostanzialmente invariate.
- Il **tuning della soglia** ha abbassato la soglia di decisione a 0.358 per raggiungere il target di sensibilita' ≥ 0.95 *sul validation set* (recall val = 0.952). Sul test set held-out la stessa soglia produce recall = 0.931 - sotto il target: la soglia non generalizza pienamente, conseguenza del piccolo validation split e di un possibile leakage a livello paziente.
- La **Test-Time Augmentation (TTA)** media le probabilita' softmax su cinque viste deterministiche (originale, flip orizzontale, rotazione ± 7 gradi, zoom $\pm 8\%$). Migliora tutte le metriche - la recall sale da 0.920 a 0.942 e l'AUC da 0.981 a 0.990 - al costo di un tempo di inferenza 5x.
- L'**ensembling** e' lasciato come lavoro futuro: richiederebbe l'addestramento di piu' checkpoint indipendenti (~ 4 h ciascuno sulla GPU disponibile) ed era fuori dallo scope di questa iterazione.

Anche con la TTA il modello deep (AUC 0.990) si avvicina ma non supera la baseline SVM (AUC 0.996): su questo dataset piccolo e ben separabile, l'SVM su feature handcrafted resta il modello piu' forte.

Calibrazione

La calibrazione dell'SVM e' gia' ottima (ECE = 0.027, Brier = 0.024 - vedere la tabella di confronto). Per il modello deep, il temperature scaling sui logit di validazione e' implementato in `src/postprocess.py:temperature_scaling` (LBFGS sullo scalare T) ed e' invocato da `scripts/calibrate_and_evaluate.py`. Sul checkpoint addestrato ha trovato $T = 1.002$: il modello era gia' ben calibrato. Il diagramma di reliability prima/dopo lo scaling e' salvato in `models/postprocess/reliability_diagram.png`; con $T = 1.002$ le due curve si sovrappongono quasi del tutto.

Analisi degli errori

Data leakage

Il dataset non contiene identificatori paziente. Se piu' slice dello stesso paziente compaiono sia nel training sia nel test, il modello potrebbe memorizzare feature paziente-specifiche (es. ombre delle costole, ispessimenti pleurici) anziche' pattern rilevanti per la patologia. Questo gonfia l'AUC misurato e potrebbe non riflettere la vera generalizzazione fuori distribuzione.

Mitigazione: i risultati sono etichettati chiaramente come potenzialmente ottimistici; per una valutazione in produzione si raccomanda uno split stratificato per paziente.

Distribution shift

Le immagini provengono da un singolo paese (Brasile) attraverso due ospedali. Le prestazioni potrebbero degradare su dati acquisiti con scanner diversi, spessori di slice diversi o demografie differenti.


Sbilanciamento delle classi

Il dataset e' approssimativamente bilanciato (1252 COVID vs 1229 non-COVID), quindi lo sbilanciamento non e' un problema primario. Tuttavia, il tuning della soglia sacrifica intenzionalmente la specificita' per raggiungere il target recall ≥ 0.95 .

Esempi qualitativi

La figura sottostante mostra slice TP / TN / FP / FN selezionate dalle predizioni SVM sul test set. I due casi errati sono i piu' informativi: nello slice FP, artefatti simili a ground-glass in un'immagine non-COVID ingannano il classificatore; nello slice FN, l'area lesionata e' piccola o periferica e i descrittori di texture globali non riescono a catturarla.

SVM qualitative examples on the held-out test set



Smoke test vs training completo

In fase di sviluppo iniziale sono stati usati smoke test su CPU (50 immagini, 1 epoca per fase) puramente come test di integrazione; quei numeri non riflettono prestazioni addestrate e non sono riportati. Le metriche del modello deep nella tabella sopra derivano dal run completo di 40 epoche sull'intero dataset (RTX 3080, 3 h 59 min). I numeri di SVM e Random Forest derivano dalle rispettive pipeline, addestrate a convergenza su CPU sull'intero dataset.


Considerazioni etiche

Non destinato all'uso clinico

Questo progetto e' un esercizio accademico e non e' stato sottoposto alla validazione richiesta per la certificazione come dispositivo medico (es. marcatura CE, FDA 510(k)). Non deve essere utilizzato per supportare diagnosi cliniche o decisioni terapeutiche.

Trasparenza del modello

Grad-CAM (`scripts/generate_gradcam.py`) evidenzia le regioni che guidano ciascuna predizione. La figura seguente mostra un esempio per ogni categoria della confusion matrix (TP / TN / FP / FN) dal test set: per i veri e i falsi positivi l'attivazione si concentra sul parenchima polmonare, a supporto della plausibilita' delle feature apprese. Le mappe di salienza restano comunque insufficienti per una spiegabilita' di livello clinico.



Bias ed equita'

I dati demografici del dataset (eta', sesso, comorbidita') non sono pubblicamente documentati, quindi non e' possibile valutare le disparita' di prestazione tra sottogruppi di pazienti. Qualsiasi deployment richiederebbe una valutazione prospettica su una popolazione rappresentativa.

Provenienza dei dati

Il dataset SARS-CoV-2 CT-Scan e' stato raccolto sotto supervisione etica in Brasile [1] ed e' distribuito sotto licenza Creative Commons Attribution 4.0. Nessuna informazione personalmente identificabile e' inclusa nei file PNG.

Riferimenti

- [1] Soares, E., Angelov, P., Biaso, S., Froes, M. H., & Abe, D. K. (2020). *SARS-CoV-2 CT-scan dataset: A large dataset of real patients CT scans for SARS-CoV-2 identification*. medRxiv. <https://doi.org/10.1101/2020.04.24.20078584>
- [2] Hofmanninger, J., Prayer, F., Pan, J., Roehrich, S., Prosch, H., & Langs, G. (2020). *Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem*. European Radiology Experimental, 4(1), 50. <https://doi.org/10.1186/s41747-020-00173-2>
- [3] Tan, M., & Le, Q. V. (2019). *EfficientNet: Rethinking model scaling for convolutional neural networks*. ICML 2019.